Didattica integRativa EseRcitazioni pRatiche con il software R

dott. Luca Menghini Ph.D.

Assegnista di ricerca, Dipartimento di Psicologia, Università degli Studi di Bologna

luca.menghini3@unibo.it

Analisi dei dati in ambito di comunità

Corso di laurea magistrale in Psicologia di comunità, della promozione del benessere e del cambiamento sociale

> Università degli Studi di Padova Anno Accademico 2021 - 2022







Mi presento

- 2014: Triennale in Scienze Psicologiche Sociali e del Lavoro @uniPD
 - "Biofeedback training per la gestione dello stress nei contesti organizzativi"
- 2016: Magistrale in Psicologia Sociale, del Lavoro e della Com. @uniPD
 - "Un Protocollo di Assessment Psicofisiologico per la Valutazione del Rischio Stress lavoro-correlato"
- 2017-2021: Dottorato in Scienze Psicologiche @uniPD
 - "Workplace stress in real time: Towards the psychophysiological assessment of stressors and strain under ecological conditions"
- 2020: Esperienza di ricerca all'estero @SRI International (CA, USA)
 Accuratezza e uso Sleep Consumer Technology, Relazioni giornaliere tra sonno e stress
- 2021: Assegno di ricerca @uniBO
 - "State workaholism as a predictor of daily fluctuations in blood pressure, emotional exhaustion, and sleep quality"

Obiettivi delle eseRcitazioni

- Acquisire competenze di base nell'uso del software R
- Consolidare le conoscenze apprese nel corso
- Implementare le tecniche analitiche apprese durante il corso utilizzando il software R su dataset reali
- Svolgere insieme gli esercizi propedeutici all'esame

Le slide e tutti materiali usati nelle eseRcitazioni verranno di volta in volta caricati e aggiornati sulla repository all'indirizzo https://github.com/Luca-Menghini/eseRcitazioni

Programma incontri facoltativi

- Giorno 1 (Get started): Installare R e RStudio, acquisire confidenza con l'interfaccia del software, e alcuni comandi di base
- Giorno 2 (R objects): Vettori, fattori, matrici e dataframe
- Giorno 3 (R workspace): Worskpace e working directory, caricare un dataset e calcolare le principali statistiche descrittive
- Giorno 4 (Graphics): Visualizzare i dati e interpretare i principali tipi di grafici
- Giorno 5 (Linear Models): Modelli di regressione lineare
- Giorno 6 (Linear Mixed-Effects and Structural Equation Models): Regressione multilivello e path analysis

Get started

Il linguaggio R



- R è un linguaggio e un ambiente di programmazione per il calcolo statistico e la visualizzazione grafica dei dati
- basato sul 'linguaggio S' (Becker & Chambers, 1984), usato per creare il software
 S-Plus e poi R, creato da Ross Ihaka e Robert Gentleman, nel 1996
- oggi sviluppato da un gruppo di ricerca internazionale (*R Core Team*), che aggiorna periodicamente (ogni anno) il programma di base (*Base R*)
- progressiva ed esponenziale aggiunta di nuovi pacchetti (packages) che ne estendono le funzionalità

Il linguaggio R



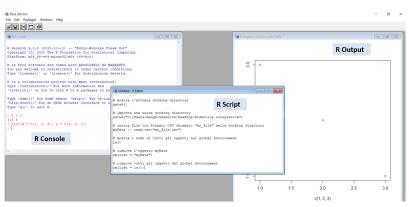
- ampia varietà di tecniche statistiche (es. modelli lineari e non lineari) e grafiche (es. pacchetto ggplot2 - link a lezione dedicata)
- pensato per essere semplice ma al contempo in grado di generare output di alta qualità (grafici, tabelle e report con equazioni e simboli matematici, ecc.);
 funzioni di default ottimizzate + possibilità di avere il pieno controllo
- software gratuito (GNU General Public License), open source (ogni funzione
 è documentata e visibile in dettaglio) che funziona su tutti i principali sistemi
 operativi: Windows, MacOS, e UNIX (es. Linux)
- enorme comunità di utenti (per qualsiasi problema, basta googlare ;-))

Scaricare e installare R



- Scaricare R dal sito https://www.r-project.org/
 CRAN (Comprehensive R Archive Network): rete di server che offrono le versioni aggiornate e la relativa documentazione
- Cliccare sulla voce CRAN nel menu Download a sinistra, selezionare un mirror (es. il primo, oppure quello dell'Università di Padova), quindi il proprio sistema operativo (Linux, MacOS, o Windows)
- Installare R aprendo il file .exe (Windows) o .pkg (MacOS) appena scaricato, oppure seguire i comandi in base alla propria versione di Linux

L'interfaccia di Base R



- R Console: per scrivere (>) ed eseguire (tasto Enter) velocemente dei comandi
- R Script (menu File > New R Script): per scrivere, modificare e salvare sequenze di comandi (salvati con formato .R)
- Outputs (es. plot): finestre che si aprono lanciando il relativo comando

Alcuni comandi elementari

Commenti (#)

questo è un commento

Semplici operazioni matematiche

```
2 + 2 # addizione
```

[1] 4

2 * 2 # moltiplicazione

Γ17 4

log(3) # logaritmo naturale

[1] 1.098612

exp(1) # funzione esponenziale

[1] 2.718282

Espressioni più lunghe (con **parentesi tonde**)

```
sqrt(5) * ( (4 - 1/2)^2 - pi/2^(1/3) )
```

[1] 21.81623

```
Assegnare valori a degli oggetti (<-)
```

```
x <- 3 # creo oggetto 'x' associato al valore 3
x # stampo il valore di x
[1] 3</pre>
```

I nomi degli oggetti possono includere lettere, numeri, trattini bassi e punti (es. pippo,

```
pippo_32 <- x / 3
```

pippo_32 # stampo il valore di pippo_32

R è sensibile alle maiuscole!

pippo32, pippo.32, pippo_32)

Mentre non è sensible agli spazi

```
3+2
[1] 5
```

3 + 2

[1] 5

Hands on: Operazioni aritmetiche con R

Calcola il risultato delle seguenti operazioni utilizzando R (soluzioni):

Source: https://psicostat.github.io/Introduction2R/first-comands.html#esercizi

1.
$$\frac{(45+21)^3 + \frac{3}{4}}{\sqrt{32 - \frac{12}{17}}}$$

$$2. \quad \frac{\sqrt{7-\pi}}{3\ (45-34)}$$

3.
$$\sqrt[3]{12 - e^2} + \ln(10\pi)$$

4.
$$\frac{\sin(\frac{3}{4}\pi)^2 + \cos(\frac{3}{2}\pi)}{\log_7 e^{\frac{3}{2}}}$$

5.
$$\frac{\sum_{n=1}^{10} r}{10}$$

Extra: Assegna il risultato dell'operazione 4 all'oggetto x, il risultato della 5 all'oggetto y, e calcola la somma x+y

RStudio



- RStudio è un ambiente di sviluppo integrato per R, che lo integra con un'interfaccia grafica ottimizzata per facilitarne l'utilizzo (es. accesso a file e oggetti, grafici, dataset, ecc.) presentando tutto in un'unica finestra
- fondato da J J Allaire nel 2009 (scritto con linguaggio Java e C++), gestito e sviluppato da gruppo di ricerca internazionale (gli stessi di tidyverse e shiny)
- gratuito e open source (GNU General Public License) + versioni a pagamento

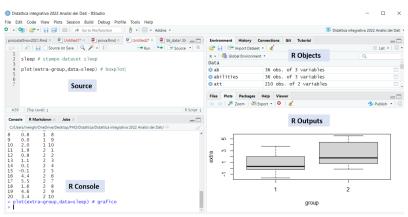
Scaricare e installare RStudio



NB: soltanto **dopo** aver installato R

- 1. Scaricare RStudio dal sito https://rstudio.com
- Cliccare sulla voce Download nel menu in alto, selezionare la versione gratuita (FREE) di RStudio Desktop, quindi il proprio sistema operativo
- 3. Installare RStudio aprendo il file appena scaricato

L'interfaccia di RStudio



- Source: R Scripts (.R), documenti e presentazioni (.Rmd), applicazioni (.app), ecc. Per
 lanciare uno o più comandi, selezionali e premi Ctrl + Enter oppure clicca sul tasto Run
 in alto a destra
- Environment (oggetti presenti nel workspace) & History (storico comandi eseguiti)

Hands on: Operatori relazionali e logici

Operatori relazionali

```
3 == 3 # uguale

[i] TRUE

3 != 3 # diverso

[i] FALSE

x >= 3 # maggiore o uguale

[i] TRUE

5 %in% c(3, 5, 8) # inclusione

[i] TRUE

Operatori logici
```

```
x <- TRUE
y <- !x # negazione
y
[1] FALSE
x & (5 < 2) # congiunzione</pre>
```

- [1] FALSE
- x | (5 < 2) # disqiunzione inclusiva
- [1] TRUE

Esercizi sugli operatori relazionali e logici: Source: https://psicostat.github.io/Introducti on2R/first-comands.html#esercizi

- Definisci una proposizione per valutare la seguente condizione: "x è un numero compreso tra -4 e -2 oppure è un numero compreso tra 2 e 4"
- Definisici due relazioni false e due vere che ti permettano di valutare i risultati di tutti i possibili incroci che puoi ottenere con gli operatori logici & e |
- Esegui le seguenti operazioni 4 ^ 3 %in% c(2,3,4) e 4 * 3 %in% c(2,3,4). Cosa osservi nell'ordine di esecuzione degli operatori?

Oggetti e funzioni

 Oggetti: identificano dei valori salvati nel workspace (Environment); i valori vengono assegnati agli oggetti con il simbolo <- (minore e meno); per richiamare un oggetto è sufficiente scrivere il suo nome

```
pippo_32 <- 2 # assegno valore a oggetto
pippo_32 # stampo oggetto
[1] 2
pippo_32 <- pippo_32 + 1 # aggiorno oggetto
pippo_32
[1] 3</pre>
```

• Funzioni: etichette associate a sequenze di comandi programmati per restituire uno specifico output (chiamato valore) sulla base di uno o più input (chiamati argomenti); il nome della funzione è sempre seguito dalle parentesi tonde, entro le quali si impostano gli argomenti (spesso ci sono dei valori di default)

```
sqrt(x = 9) # radice quadrata dell'argomento x
[1] 3
seq(from = 1, to = 5) # sequenza numerica dal valore 'from' al valore 'to'
[1] 1 2 3 4 5
```

Tipi (classi) di oggetti

```
Logical (logico)
```

x <- TRUE

x <- T class(x)

[1] "logical"

Numeric (numeri)

x < -1.4

class(x)

[1] "numeric"

Integer (numeri interi)

as.integer(x)

Γ17 1

Character (stringa di testo)

x <- "Mi piace R"

Х

[1] "Mi piace R"

```
Vector (vettore): serie di valori con la
stessa classe (es. numeric) combinati con la
funzione c() (combine)
```

```
x \leftarrow c(1, 10.5, 3, 2)
```

x + 1

[1] 2.0 11.5 4.0 3.0

sqrt(x)

[1] 1.000000 3.240370 1.732051 1.414214

v <- c("mi", "piace", "R")</pre>

```
Matrix (matrice): tabella nrow * ncol
```

```
x \leftarrow matrix(1:12, nrow = 3, ncol = 4)
rownames(x) <- y # nomi di riga
х
```

[,1] [,2] [,3] [,4] шi 10

5 piace 11 12

6 9 R objects

Un vettore (vector) è una sequenza di elementi dello stesso tipo (classe), che può essere creata con la funzione c() (combine) o con altre funzioni.

```
x <- c(1, 10.5, 3, 2) # creo vettore numerico
y <- 1:10 # un altro vettore numerico
(z <- rep(c(TRUE, FALSE), each = 2)) # vettore logico
[1] TRUE TRUE FALSE FALSE
as.character(x) # converte la classe del vettore da numeric a character
[1] "1"  "10.5" "3"  "2"
as.numeric(z) # da logical a numeric (FALSE = 0, TRUE = 1)
[1] 1 1 0 0</pre>
```

Applicando un'operazione o una funzione al vettore, questa viene applicata a tutti i suoi elementi.

```
y*2 # moltiplica tutti i valori per 2

[1] 2 4 6 8 10 12 14 16 18 20

round(sqrt(y), 2) # rad. quadrata dei valori di y, arrotondati a 2 decimali

[1] 1.00 1.41 1.73 2.00 2.24 2.45 2.65 2.83 3.00 3.16
```

Alcune funzioni restituiscono un unico valore a partire da un vettore di valori.

```
length(y) # numero di elementi nel vettore
[1] 10
```

 ${\bf Ad \ esempio, \ per \ calcolare \ delle \ statistiche \ descrittive \ su \ vettori \ numerici:}$

```
sum(y) # somma qli elementi nel vettore
Γ17 55
max(y) # valore massimo
Γ17 10
mean(y) # media
[1] 5.5
median(y) # mediana
[1] 5.5
var(y) # varianza
[1] 9.166667
sd(y) # deviazione standard
[1] 3.02765
```

Le parentesi quadre [] permettono di selezionare uno o più elementi del vettore.

```
pippo32 <- c("uno", "due", "tre", "quattro", "cinque") # vettore di caratteri
pippo32[3] # seleziono il terzo valore di pippo32
[1] "tre"
pippo32[3:4] # terzo e quarto valore del vettore pippo32
[1] "tre" "quattro"
pippo32[c(4, 2)] # quarto e secondo valore (non scrivere pippo32[4,3] !)
[1] "quattro" "due"</pre>
```

Ad esempio, si possono selezionare gli **elementi che rispettano certe condizioni**, usando gli operatori logici e relazionali:

```
y[y <= 3 | y > 8] # valori di y minori o uguali a 3 o maggiori di 8

[1] 1 2 3 9 10

pippo32[pippo32 != "due"] # valori di pippo32 diversi da "due"

[1] "uno" "tre" "quattro" "cinque"

pippo32[substr(pippo32, 2, 2) == "u"] # valori con lettera "u" in 2a posizione

[1] "due" "quattro"
```

La funzione which() restituisce la **posizione** degli elementi per cui è vera una condizione specifcata.

```
substr(pippo32, 2, 2) == "u" # testa l'equivalenza per ogni elemento
[1] FALSE TRUE FALSE TRUE FALSE
which(substr(pippo32, 2, 2) == "u") # elementi con equivalenza TRUE
[1] 2 4
pippo32[substr(pippo32,2,2)=="u"] == pippo32[which(substr(pippo32,2,2)=="u")]
[1] TRUE TRUE
```

Per cambiare uno o più elementi di un vettore, usa il simbolo <-

```
pippo32[1] <- "UNO!"
```

Per eliminare uno o più elementi da un vettore, usa il simbolo -

```
pippo32[-c(2, 4)]
[1] "UNO!" "tre" "cinque"
```

Hands on: Esercizio 1.5 (Moodle > ADcom2122 > Materiale Didattico > MateRiale eseRcizi)

Un fattore (factor) è un tipo speciale di vettore usato in R per lavorare con le **variabili** categoriali (nominali o ordinali). I valori possibili assunti dal fattore sono chiamati livelli (levels), di default ordinati in ordine crescente (numerico o alfabetico).

```
as.factor(pippo32) # da character a factor
[1] UNO!
            due
                            quattro cinque
                    tre
Levels: cinque due quattro tre UNO!
# summaru() mostra un sommario della variabile
summary(pippo32)
   Length
              Class
                         Mode
        5 character character
# per i fattori, mostra la freq. di ogni livello
summary(as.factor(pippo32)) # equivale a table()
 cinque
            due quattro
                                    IINO
                            tre
                                       1
```

```
(y <- rep(c(2,4,6),3))
[1] 2 4 6 2 4 6 2 4 6
as.factor(y) # da numeric a factor
[1] 2 4 6 2 4 6 2 4 6
Levels: 2 4 6
summary(y)
Min. 1st Qu. Median Mean 3rd Qu. Max.
2 2 4 4 6 6
summary(as.factor(y))
2 4 6
3 3 3
```

Creare un fattore con la funzione factor():

```
factor(x = c("C", rep("A", 3), c("B", "A", "C")))
[1] CAAABAC
Levels: A B C
(x <- factor(x = c("C", "A", "B", "A"), # vettore
             levels = c("C"."A"."B"))) # livelli
[1] CABA
Levels: C A B
levels(x) # levels() stampa i nomi dei livelli
[1] "C" "A" "B"
factor(x, levels=c("B","A","C")) # cambia ordine
[1] C A B A
Levels: B A C
levels(x) <- c("Uno", "Due", "Tre") # cambia nomi</pre>
Х
[1] Uno Due Tre Due
Levels: Uno Due Tre
```

```
Quando si lavora con variabili ordinali, è
possibile specificare l'ordine dei livelli
impostando l'argomento ordered = TRUE. Viene
così generato un fattore ordinato, sempre
seguendo l'ordine definito da levels.
# fattore non ordinato (default)
factor(x = c("Maria", "Mauro", "Teresa", "Carlo"))
[1] Maria Mauro Teresa Carlo
Levels: Carlo Maria Mauro Teresa
# fattore ordinato (default: ordine alfabetico)
factor(x = c("Maria", "Mauro", "Teresa", "Carlo"),
       ordered = TRUE)
[1] Maria Mauro Teresa Carlo
Levels: Carlo < Maria < Mauro < Teresa
```

Hands on: Esercizio 1.8

Tipi (classi) di oggetti: matrix

Una matrice (matrix) è una struttura bidimensionale (nrow*ncol) di elementi dello stesso tipo, che può essere creata con la funzione:

matrix(data, nrow = , ncol = , bvrow = FALSE)

```
(x \leftarrow matrix(1:12, nrow = 3, ncol = 4))
     [,1] [,2] [,3] [,4]
[1,]
       1
          4
              7 10
[2,] 2 5 8 11
[3,]
       3 6
                9 12
matrix(1:12, nrow = 3, ncol = 4, byrow = TRUE)
     [,1] [,2] [,3] [,4]
[1,]
          2
[2,]
[3.]
           10
                11
                   12
matrix(c("Mar", "Mau", "Ter", "Car"), nrow = 2)
    [,1] [,2]
[1.] "Mar" "Ter"
[2.] "Mau" "Car"
```

```
Per selezionare uno o più elementi di una
matrice, usamo ancora una volta le parentesi
quadre, ma questa volta con la sintassi
nome_matrice[num_riga, num_colonna]
x[1,2] # prima riga, seconda colonna
[1] 4
x[2,1] # seconda riga, prima colonna
[1] 2
x[1:3,2] # righe 1-3, seconda colonna
[1] 4 5 6
x[1,] # prima riga, tutte le colonne
[1] 1 4 7 10
x[.2] # seconda colonna, tutte le righe
[1] 4 5 6
```

Tipi (classi) di oggetti: matrix

```
х
                                                      Nomi e numero di righe e colonne:
     [.1] [.2] [.3] [.4]
                                                      rownames(x) <- c("a", "b", "c") # nomi righe
Γ1.7
                      10
                                                      colnames(x) <- 1:4 # nomi colonne
Γ2.1
                     11
                                                      х
[3.]
        3
            6
                     12
                                                        1234
Unire due matrici:
                                                      a 1 4 7 10
cbind(x,matrix(rep(3,6),nrow=3)) # per colonna
                                                      b 2 5 8 11
                                                      c 3 6 9 12
     [,1] [,2] [,3] [,4] [,5] [,6]
                                                      c(nrow(x), ncol(x)) # numero right e col. = dim(x)
[1,]
                     10
                                                      [1] 3 4
[2,]
            5
                    11
                                                      t(x) # matrice trasposta (inverte righe e col.)
[3,]
        3
            6
                    12
                            3
                                 3
rbind(x,matrix(rep(3,4),ncol=4)) # per riga
                                                         a b c
     [,1] [,2] [,3] [,4]
                                                            2 3
Γ1.7
                     10
Γ2.1
        2
            5
                     11
                                                      4 10 11 12
Γ3.1
        3
             6
                     12
[4,]
        3
             3
                       3
                                                      Hands on: Esercizio 1.6
```

Strutture di dati: dataframe

Un dataframe è una struttura bidimensionale di elementi di diverso tipo

```
(es. numeric, character e factor), che può essere creata con la funzione: data.frame(nome_variabile1 = c(...), nome_variable2 = c(...), ...)
```

```
(x \le data.frame(Num = 1:4.
                Char = c("a","b","c","d").
                Logi = rep(c(TRUE,FALSE),2)))
 Num Char Logi
         a TRUE
2
   2
        b FALSE
3
   3
         c TRUE
        d FALSE
str(x) # struttura del dataframe
'data.frame': 4 obs. of 3 variables:
$ Num : int 1 2 3 4
$ Char: chr "a" "b" "c" "d"
```

\$ Logi: logi TRUE FALSE TRUE FALSE

Mentre il comando str(nome_df) restituisce la struttura di un dataframe, summary(nome_df) stampa un sommario per ogni variabile.

Char	Logi
Length:4	Mode :logical
Class :character	FALSE: 2
Mode :character	TRUE :2
	Length:4 Class :character

Strutture di dati: dataframe

La manipolazione di un dataframe è molto simile a quella già vista per le matrici.

Selezione elementi e unione di due dataframe:

```
x[2, 2:3] # seconda riga, colonne 2 e 3
  Char Logi
     b FALSE
2
cbind(x,data.frame(new=4:1)) # unione per colonna
  Num Char Logi new
1
         a TRUE
                   4
2
    2
         b FALSE
3
         c TRUE
         d FALSE
rbind(x[1:3,],data.frame(Num=10, # per riga
                         Char="z",Logi=FALSE))
  Num Char Logi
         a TRUE
    2
         b FALSE
3
    3
         c TRUE
   10
         z FALSE
```

```
Nomi e numero di righe e colonne:

rownames(x) # default = 1:nrow(x)

[1] "1" "2" "3" "4"

colnames(x)[2] # nome colonna 2

[1] "Char"

nrow(x)

[1] 4

ncol(x)

[1] 3
```

Γ.31

11311

"FALSE" "TRUE" "FALSE"

[.4]

11411

"6"

Trasporre un dataframe:

[.2]

"b"

t(x)

Nıım

Char "a"

[.1]

Strutture di dati: dataframe

x[,"Logi"]



Per selezionare una colonna (vettore) di un dataframe, si può usare il simbolo \$, con la sintassi nome_dataframe\$nome_colonna:

```
x$Char # seleziono colonna Char
[1] "a" "b" "c" "d"
x$Char[2] # secondo elemento della colonna Char
Г17 "Ъ"
x$Char[2] == x[2,2] # due comandi equivalenti
[1] TRUE
x$Char <- NULL # elimino colonna Char
x[x$Num < 3,] # seleziono casi con Num < 3
  Num Logi
      TRUE
    2 FALSE
# stesso risultato con subset(x, Num < 3)
```

Modo alternativo di selezionare le colonne:

```
[1] TRUE FALSE TRUE FALSE
x[1:2,c("Num","Logi")]
 Num Logi
   1 TRUE
   2 FALSE
"Testa" e "coda" di un dataframe:
head(x, n = 2) # prime due righe
 Num Logi
   1 TRUE
   2 FALSE
tail(x, 1) # ultima riga
 Num Logi
   4 FALSE
```

Hands on: Esercizio 1.9

Strutture di dati: list

Una lista (*list*) è una raccolta di oggetti che possono avere diversa classe (es. vector, matrice e dataframe) e diversa lunghezza (al contrario di matrici e dataframe). Si tratta della struttura più complessa eversatile di R, e si crea con la funzione list(nome oggetto1 = ..., nome oggetto2 = ..., ...)

```
x \leftarrow list(Num = 1:4,
          Matr = matrix(1:12, nrow=3),
          df = x,
          lst = list(1:3,2:3))
str(x) # struttura del dataframe
List of 4
 $ Num : int [1:4] 1 2 3 4
 $ Matr: int [1:3, 1:4] 1 2 3 4 5 6 7 8 9 10 ...
 $ df : 'data.frame': 4 obs. of 2 variables:
  ..$ Num : int [1:4] 1 2 3 4
  ..$ Logi: logi [1:4] TRUE FALSE TRUE FALSE
 $ 1st :List of 2
  ..$: int [1:3] 1 2 3
  ..$: int [1:2] 2 3
```

Per **selezionare gli elementi** di una lista, usiamo sempre le **parentesi quadre**

```
x[1] # singole = crea sotto-lista
$Num
[1] 1 2 3 4
class(x[1])
[1] "list"
x[[1]] # doppie = estrae l'oggetto
[1] 1 2 3 4
class(x[[1]])
[1] "integer"
x[[3]][2,1]
[1] 2
```

R workspace

Funzioni e pacchetti

Molte cose in R si fanno usando delle funzioni, composte dai seguenti elementi: nome,

parentesi tonde, argomenti (nomeArgomento = valoreArgomento oppure senza nome, in base alla
posizione di default), valore restituito (value)

```
sqrt(x = c(1,2,3))
[1] 1.000000 1.414214 1.732051
sqrt(c(1,2,3))
[1] 1.000000 1.414214 1.732051
```

R Help system: Per conoscere i dettagli (argomenti) di qualsiasi funzione, basta inserire il simbolo ? seguito dal nome della funzione

```
?sqrt
```

R packages: Per ottenere funzioni aggiuntive rispetto a quelle dei pacchetti di base, è necessario installare e aprire il relativo pacchetto (package)

```
install.packages("nome_pacchetto") # installare un pacchetto
library(nome_pacchetto) # apripre un pacchetto
nome_pacchetto::nome_funzione() # usare funzione senza aprire il pacchetto
```

Oggetti, funzioni e workspace

Quando assegnamo un valore ad una variabile, questa viene registrata nel **workspace**: il posto che contiene tutti gli oggetti e le funzioni definiti dall'utente (sezione Environment di RStudio).

La funzione ls() stampa i nomi di tutti gli oggetti e le funzioni presenti nel workspace, mentre la funzione rm() rimuove l'oggetto specificato tra parentesi:

```
x <- 1 # assegno valore a x
y <- 2 # assegno valore a y
ls() # mostra tutti gli oggetti nel workspace
[1] "x" "y"
rm(y) # rimuove l'oggetto y
ls()
[1] "x"</pre>
```

Combinando le due funzioni, il comando rm(list=ls()) svuota il workspace, eliminando tutti gli oggetti e le funzioni (molto utile all'inizio di ogni script!)

```
rm(list = ls())
```

Oggetti e funzioni già inclusi in Base R

Alcuni pacchetti di base (oggetti e funzioni) sono **già installati in R**. Questi non richiedono l'apertura di nessun pacchetto e non compaiono nel workspace.

```
rm(list=ls()) # svuoto il workspace
head(sleep.4) # dataset sleep dal pacchetto datasets
 extra group ID
   0.7
           1 1
2 -1.6 1 2
3 -0.2 1 3
           1 4
4 -1.2
mean(sleep$extra) # funzione mean() dal pacchetto base
[1] 1.54
letters[2] # costanti dal pacchetto base
Г1] "b"
ls() # il workpace è vuoto!
character(0)
```

Caricare oggetti dall'esterno: La working directory

Per aprire un file che si trova in una specifica cartella, è necessario prima impostare la working directory, ovvero la cartella dalla quale vengono importati i file di input e nella quale vengono esportati i file di output.

```
getwd() # funzione per stampare la WD attuale
[1] "C:/Users/mengh/OneDrive/Desktop/PHD/Didattica/Didattica integrativa 2022 Analisi dei dir()[1:3] # stampa i primi 3 file nella WD
[1] "appunti Pastore.didattica integrativa.txt"
[2] "Cartel1.csv"
[3] "Cartel1.xlsx"
setwd("data") # sottocartella nella WD
setwd("C:/Users/mengh/OneDrive/Desktop") # nuova directory
```

Trucchetto con RStudio: ogni volta che inizi un nuovo progetto (es. analisi tesi, report progetto), crea un nuovo R project (.Rproj) dal menu File > New R Project, selezionando una directory esistente o creandone una nuova. Così quella sarà già impostata come la WD per tutti i file associati al progetto.

Caricare ed esportare un dataset

Il primo passo di ogni analisi dei dati con R è quello di caricare una struttura di dati (registrati con un certo metodo e salvati con un certo formato) nel workspace.

Per caricare un dataset che si trova nella working directory, è necessario usare una specifica funzione in base al formato del file.

```
# file .RData
load(file = "data/questionarioStudenti.RData") # import
save(qs, file = "data/questionarioStudenti.RData") # export
```

R può importare ed esportare dati salvati con molti formati diversi, alcuni dei quali richiedono l'installazione di pacchetti aggiuntivi.

```
# file .CSV (comma separated values)
qs <- read.csv(file = "data/questionarioStudenti.csv") # import
write.csv(x = qs, "data/questionarioStudenti.csv", row.names = FALSE) # export

# file .SAV (da SPSS)
library(foreign)
qs <- read.spss("data/questionarioStudenti.sav", to.data.frame=TRUE)</pre>
```

Caricare ed esportare un dataset

Un modo veloce (ma poco riproducibile!) per caricare un file su R è usare la funzione file.choose() al posto del nome del file. Questo consente di caricare un file senza nemmeno dover impostare la WD.

```
qs <- read.csv(file = file.choose())</pre>
```

Se hai dubbi su quale funzione usare per leggere un file, puoi usare il menu punta-e-clicca di RStudio: File > Import Dataset

Hands on:

- Apri o crea un file .xlsx sul tuo PC, salvalo in formato .csv (comma separated values) e importalo su R
- Prova ad importare direttamente il file .xlsx (se hai dubbi, cerca su Google "how to read xlsx file with R")
- In entrambi i casi, osserva la classe e la struttura dell'oggetto importato

Hands on: Questionario incontri facoltativi

- Scarica i file questionarioStudenti.RData e questionarioStudenti.csv da Github: https://github.com/Luca-Menghini/eseRcitazioni/tree/main/data (Premere su File > Raw > Download o tasto dx > Save as), salva il file in una cartella e imposta quella cartella come working directory.
- 2. Importa entrambi i file su RStudio e confronta i due oggetti. Di che classe sono? E le variabili di che classe sono?
- 3. Usa la funzione describe() del pacchetto psych (forse va prima installato!) per calcolare le statistiche descrittive della variabile numVar e usa la funzione hist() per visualizzare il grafico di densità ad istogrammi (prova a cambiare il valore dell'argomento breaks).
- Usa la funzione table() per produrre la tabella di frequenza della variabile Q02 ("Quale giorno preferiresti per gli incontri facoltativi?")
- Ora fai la stessa cosa, ma considerando solo chi ha risposto "Sì" alla domanda Q01 ("Parteciperai a tutti gli incontri?")
- Ora incrocia le frequenze delle variabili Q02 e Q03 ("Riusciresti a partecipare anche se fossero nel giorno che NON hai scelto?")

Statistiche descrittive (univariate)

```
table(x) # frequenze assolute
x \leftarrow c(1.1.1.2.8.9) # creo vettore numerico
                                                      х
                                                      1289
c(mean(x), median(x)) # media & mediana
                                                      3 1 1 1
[1] 3.666667 1.500000
                                                      round(table(x)/length(x),2) # freq relative
as.numeric(which.max(table(x))) # moda
T11 1
                                                      x
                                                         1
                                                              2 8
c(var(x).sd(x)) # varianza & dev. standard
                                                      0.50 0.17 0.17 0.17
[1] 14.266667 3.777124
                                                      cumsum(x) # somma cumulata
quantile(x,probs=0.90) # 90° percentile
                                                      [1] 1 2 3 5 13 22
90%
                                                      cumsum(table(x)) # freq cumulate assolute
8.5
                                                      1289
quantile(x,probs=c(0.25,0.50,0.75,1)) # quartili
                                                      3 4 5 6
 25% 50% 75% 100%
                                                      round(cumsum(table(x)/ # freq cumulate relative
 1.0 1.5 6.5 9.0
                                                                     length(x)), 2)
round(rank(x)/length(x),2) # ranghi percentili
                                                         1
                                                              2
[1] 0.33 0.33 0.33 0.67 0.83 1.00
                                                      0.50 0.67 0.83 1.00
```

Statistiche descrittive (bivariate)

```
y <- -x - 1 # valori inversamente prop. a x
z <- round(rnorm(n=length(x)),1) # valori a caso
(df <- data.frame(x,y,z)) # nuovo dataframe
                                                          Quando ho più di due variabili:
          z
                                                          cov(df) # matrice di covarianza
1.1 - 2. - 0.7
                                                                                ٧
                                                                                           z
2 1 -2 -0.8
                                                          x 14.266667 -14.266667 -2.0333333
3 1 -2 1.0
                                                          y -14.266667 14.266667 2.0333333
4 2 -3 0.7
                                                          z -2.033333 2.033333 0.9106667
5 8 -9 -1.4
6 9 -10 -0.8
                                                          cor(df) # matrice di correlazione
Correlazione e covarianza
                                                                     х
                                                          x 1.0000000 -1.0000000 -0.5641149
cov(x,y) # covarianza tra x e y
                                                          v -1.0000000 1.0000000 0.5641149
[1] -14.26667
                                                          z -0.5641149 0.5641149 1.0000000
cor(x,y) # correlazione
```

Γ17 -1

Esercizi

- Esercizio 1.10*
- Esercizi 1.11-1.13*
- Esercizio 1.26**
- *I dataset sono inclusi nella cartella dati.esercizi.zip su Moodle
 (ADcom2122 > Materiale didattico > MateRiale eseRcizi), ma si possono scaricare
 anche da github.com/Luca-Menghini/eseRcitazioni/tree/main/data

**Per scaricare il pacchetto ADati del prof. Pastore, esegui i seguendi comandi collegandoti ad una rete wifi:

```
install.packages("devtools") # installo pacchetto devtools
library(devtools) # apro pacchetto devtools
install_github("https://github.com/masspastore/ADati") # installo ADati da github
library(ADati) # apro pacchetto ADati
```

Graphics

Graphics in R: Principali funzioni

Funzioni di alto livello (stanno in piedi da sole)

```
# funzione base (dipende dalla classe dell'oggetto)
plot() # scatter plot (grafico a dispersione)
# distribuzione
boxplot() # boxplot (diagramma a scatola e a baffi)
qqnorm() # quantile-quantile plot
# frequenze
barplot() # grafico a barre (variabili categoriali)
hist() # istogramma (variabili continue)
pie() # pie chart
# interazioni
interaction.plot()
```

Funzioni di basso livello (aggiungono elementi alle prime)

```
points() # aggiunge punti
lines() # aggiunge linee
text() # aggiunge del testo
# retta di regressione lineare
abline(a = ..., b = ...)
# elementi più complessi
rect() # aggiunge rettangoli
polygon() # aggiunge poligoni
# altre caratteristiche del grafico
axis() # per modificare qli assi
legend() # per aggiungere una legenda
```

Parametri grafici

Esegui il comando ?par per vedere tutti i parametri grafici modificabili.

Alcuni possono essere impostati usando gli argomenti delle funzioni grafiche:

```
# dimensioni
cex = 2 # grandezza testo e simboli (moltiplicatore)
lwd = 0.5 # spessore linee
# colore e forma
col = "red" # (vedi ?colors)
lty = 2 # tipo di linee (1=solid, 2=dashed, ...)
pch = 19 # forma dei punti (vedi ?points)
# titoli
main = "Titolo del grafico"
xlab = "Titolo asse x"
```

Altri devono essere impostati all'interno della funzione par(), che va eseguita prima di generare il grafico:

```
# margini (bottom, left, top, right)
mai # dimensione margini (in ince)
mar # dimensione margini (in linee di testo)

# struttura griglie di grafici
mfrow=c(nrow, ncol)
# es. due grafici uno di fianco all'altro
mfrow=c(2,1)
# es. due grafici uno sotto l'altro
mfrow=c(1,2)
```

Distribuzioni univariate: variabili continue

```
X <- rnorm(n=100, mean=0, sd=1) # genero valori casuali dalla distribuzione normale standard

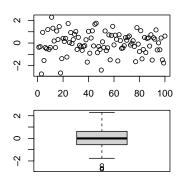
par(mfrow = c(2,2), mai = c(0.3,0.5,0.2,0.5)) # voglio 4 grafici in una sola finestra

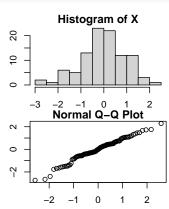
plot(X) # scatter plot: grafico a dispersione (variabilità)

hist(X) # istogramma: distribuzione di frequenze per classi

boxplot(X) # box plot: diagramma a scatola (1° e 3° quartile) e a baffi (+/- 1.5 IQR)

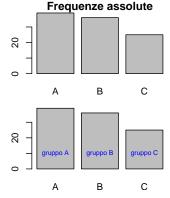
qqnorm(X) # Q-Q plot: distribuzione cumulata di X vs. distribuzione cumulata normale)
```

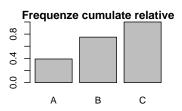




Distribuzioni univariate: variabili categoriali

```
Y <- factor(sample(x=c("A","B","C"),size=100,replace=TRUE)) # frequenze casuali per A, B e C
par(mfrow = c(2,2), mai = c(0.3,0.5,0.2,0.5)) # voglio 4 grafici in una sola finestra
barplot(table(Y), main="Frequenze assolute") # grafico a barre: mostra le frequenze assolute
barplot(round(cumsum(table(Y)/length(Y)),2), main="Frequenze cumulate relative")
barplot(table(Y)) # stesso grafico ma aggiungo del testo in blu
text(x=c(0.7,1.9,3.1),y=10,labels=c("gruppo A","gruppo B","gruppo C"),col="blue",cex=0.7)
```

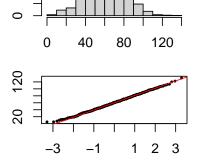


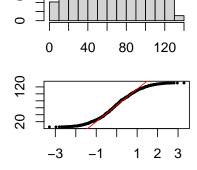


Valutare la normalità di una distribuzione

```
X <- rnorm(n = 1000, mean = 60, sd = 20) # norm
par(mfrow=c(2,1),mai=rep(0.3,4),mar=rep(1.8,4))
hist(X,main="",xlab="",ylab="") # istogramma
qqnorm(X,cex=0.5,main="",pch=20) # Q-Q plot
qqline(X,col="red") # aggiungo linea distr. norm.</pre>
```

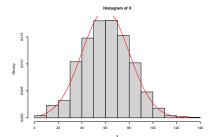
```
Y <- runif(n=1000,min=min(X),max=max(X)) # unif
par(mfrow=c(2,1),mai=rep(0.3,4),mar=rep(1.8,4))
hist(Y,main="",xlab="",ylab="") # istogramma
qqnorm(Y,cex=0.5,main="",pch=20) # Q-Q plot
qqline(Y,col="red") # aggiungo linea distr. norm.
```



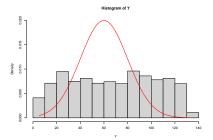


Valutare la normalità di una distribuzione

```
# Distribuzione empirica
hist(X, freq = FALSE)
# Distribuzione teorica (attesa)
curve(dnorm(x, mean = 60, sd = 20),
    from = min(X), to = max(X),
    col = "red", lwd = 2,
    add = TRUE)
```



```
# Distribuzione empirica
hist(Y, freq = FALSE, ylim = c(0,0.02))
# Distribuzione teorica (attesa)
curve(dnorm(x, mean = 60, sd = 20),
    from = min(Y), to = max(Y),
    col = "red", lwd = 2,
    add = TRUE)
```



Valutare la normalità di una distribuzione

```
library(moments) # asimmetria e curtosi
                                                       # asimmetria e curtosi
                                                       c(skewness(Y), kurtosis(Y)) # (buono se ~ 0)
c(skewness(X), kurtosis(X)) # (buono se ~ 0)
[1] 0.07460993 2.86593370
                                                       [1] -0.01969742 1.79996960
# test Kolmogorov-Smirnov (HO: X è normale)
                                                       # test Kolmogorov-Smirnov (HO: Y è normale)
                                                      ks.test(Y, v="pnorm", mean=mean(Y), sd=sd(Y))
ks.test(X, y="pnorm", mean=mean(X), sd=sd(X))
    One-sample Kolmogorov-Smirnov test
                                                          One-sample Kolmogorov-Smirnov test
                                                      data: Y
data: X
                                                      D = 0.068059, p-value = 0.0001895
D = 0.016111, p-value = 0.9575
alternative hypothesis: two-sided
                                                      alternative hypothesis: two-sided
                                                       # test Shapiro-Wilk (HO: Y è normale)
# test Shapiro-Wilk (HO: X è normale)
                                                       shapiro.test(Y)
shapiro.test(X)
    Shapiro-Wilk normality test
                                                          Shapiro-Wilk normality test
                                                      data: Y
data: X
W = 0.99862, p-value = 0.6372
                                                       W = 0.95546, p-value < 2.2e-16
```

Distribuzioni bivariate: variabili continue

```
Y <- rnorm(1000, mean=20, sd=1) # Y (indipendente da X)
Z <- X + rnorm(1000, sd = 20) # Z (proporzionale a X)

# Scatter plot

par(mfrow=c(2,1),mai=rep(0.3,4),mar=rep(1.8,4),cex=.5)

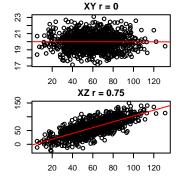
plot(X, Y, main = paste("XY r =",round(cor(X, Y),2)))

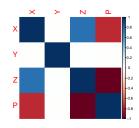
abline(lm(Y-X),col="red") # retta di regr. lineare

plot(X, Z, main = paste("XZ r =",round(cor(X, Z),2)))

abline(lm(Z-X),col="red") # tilde (-) con Alt + 1-2-6
```





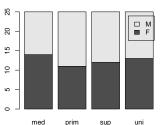


Distribuzioni bivariate: variabili categoriali

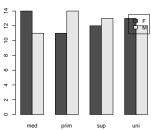
```
table(df) # frequenze incrociate
   edu

sex med prim sup uni
   F 14   11   12   13
   M   11   14   13   12

par(mai=rep(0.4,4))
barplot(table(df),legend.text = TRUE) # bar plot
```

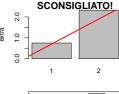


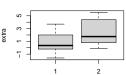


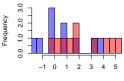


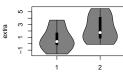
Distribuzioni bivariate: continue & categoriali

library(vioplot); vioplot(extra ~ group, data = sleep) # grafico a violino: densità per gruppo









Salvare un grafico

2

Esercizi

Introduzione a R:

- 1.22 (distribuzioni di probabilità)
- 1.26 (dataset, descrittive e grafici)*

Teoria dei campioni

- 2.2 (popolazione e distr. campionarie)
- 2.8 (variabili casuali e distr. campionarie)
- $2.14~({\rm dataset,\; campioni\; e\; probabilit\`a})**$

Inferenza statistica

- 3.4 (dataset, grafici e test statistici)**
- 3.11 (grafici, test e potenza statistica)

*Per scaricare il pacchetto ADati del prof. Pastore:

```
install.packages("devtools")
library(devtools)
install_github("https://github.com/masspastore/ADati")
library(ADati)
```

*Per caricare un dataset dal pacchetto ADati:

```
data(gambling, # nome del dataset
package = "ADati")
```

**I dataset sono inclusi nella cartella
dati.esercizi.zip su Moodle (ADcom2122 > Materiale
didattico > MateRiale eseRcizi), ma si possono
scaricare anche da github.com/LucaMenghini/eseRcitazioni/tree/main/data

LM

LMER & SEM

Risorse

Risorse: Primi passi con R

In italiano:

- Callagher, C. Z., & Gambarota, F. (2021). Introduzione a R. Corso introduttivo online: https://psicostat.github.io/Introduction2R
- Agostinelli, C. (2000). Introduzione a R. Corso introduttivo PDF: https://cran.r-project.org/doc/contrib/manuale.0.3.pdf
- Pastore, M. (2015). Analisi dei dati in Psicologia (Con applicazioni in R). Bologna: Il Mulino.

In inglese:

- R Core Team. The R Manuals. Manuali in formato pdf: https://cran.r-project.org/manuals.html (in particolare An Introduction to R (with many examples, R Data Import/Export)
- UniGlasgow PsyTheacR. Corso interattivo analisi dati con R: https://psyteachr.github.io/
- Dalgaard, P. (2008). Introductory statistics with R. New York: Springer.

Risorse: argomenti specifici

Graphics:

- Videolezioni di appRofondimento sul pacchetto ggplot2: disponibili su Moodle https://elearning.unipd.it/scuolapsicologia/mod/page/view.php?id=150311
- Murrell (2011) R Graphics (II edition). New York: Chapman and Hall/CRC. Esempi con codice disponibili al sito
 https://www.stat.auckland.ac.nz/~paul/RGraphics/rgraphics.html

Contatti



dott. Luca Menghini, Ph.D.

Assegnista di ricerca, Dipartimento di Psicologia, Università degli Studi di Bologna

luca. menghini 3@unibo. it

Linkedin | ResearchGate | GitHub | Twitter